

Patrones Espaciales de Índices de Vegetación Satelital en las Provincias de Puno, Perú: Análisis de Autocorrelación, LISA y Kriging Ordinario con Landsat 8

V. R. Maye Mamani

vmaye@est.unap.edu.pe

J. J. Mulluni Candia

jmulluni@est.unap.edu.pe

J. C. Gonzales Quispe F. E. Quispe Camacutipa

j.gonzales@est.unap.edu.pe

frquispecam@est.unap.edu.pe

Universidad Nacional del Altiplano, Puno, Perú

Resumen

Se analizó la distribución espacial de cuatro índices de vegetación espectral —NDVI, SAVI, EVI y NDMI— derivados de imágenes Landsat 8 sobre una grilla de 5 km en las 13 provincias de Puno, Perú ($n = 3019$ puntos, n efectivo terrestre = 2845). Se evaluó su relación con variables ambientales (elevación, precipitación, temperatura) mediante correlaciones de Pearson y Spearman, se cuantificó la autocorrelación espacial con el Índice de Moran Global y Local (LISA, k -NN, $k = 8$, 999 permutaciones Monte Carlo) y se aplicó Kriging Ordinario para generar superficies continuas de NDVI y NDMI a 2 km de resolución con validación cruzada (10-fold CV). Los resultados revelan: (a) autocorrelación espacial excepcionalmente alta (I de Moran 0,86–0,92, $p < 0,001$); (b) EVI como el índice de mejor desempeño (EVI-Elevación $r = -0,898$), con NDVI, SAVI y EVI mostrando multicolinealidad severa ($VIF > 20$) y NDMI independiente ($VIF = 4,2$); (c) NDMI detecta el doble de estructura espacial que NDVI en LISA (45.1 % vs. 31.0 %), con el 67.7 % del departamento presentando NDMI negativo; (d) Kriging Ordinario con $R^2 > 0,85$ en validación cruzada y alcances de 170–190 km; y (e) cuatro regímenes provinciales de relación EVI-altitud, incluyendo un gradiente positivo significativo en Huancané ($r = +0,222$, $p = 0,013$). La integración de estos métodos ofrece una herramienta viable para el monitoreo ambiental en territorios de alta montaña.

Palabras clave: NDVI, EVI, NDMI, Moran I, LISA, Kriging Ordinario, Landsat 8, Puno, provincias, bofedales, autocorrelación espacial.

1. Introducción

Las regiones montañosas cubren aproximadamente el 24 % de la superficie terrestre y son ecosistemas particularmente sensibles al cambio climático y a las presiones antropogénicas. El monitoreo de la vegetación en estos territorios es esencial para la planificación agrícola, la gestión de recursos hídricos y la conservación de la biodiversidad. Los índices de vegetación (VIs) derivados de sensores remotos —NDVI, SAVI, EVI y NDMI— constituyen herramientas eficaces para caracterizar la biomasa fotosintética, la humedad y el estrés hídrico a escala regional [4]. Sin embargo, su aplicación en zonas de montaña requiere consideraciones especiales: la topografía introduce variaciones en la geometría sol-sensor que pueden comprometer la confiabilidad de estos índices [5], y los efectos de sombra y pendiente deben ser explícitamente modelados.

Yan et al. [6] realizaron una revisión sistemática global de VIs, mientras que Vidican et al. [8] documentaron sus aplicaciones en el monitoreo agrícola.

En el contexto peruano, diversos estudios han aprovechado las imágenes Landsat para caracterizar la vegetación andina. Carbajal-Morán et al. [9] evaluaron el NDVI durante 30 años (1993–2022) en el valle de Tayacaja, Andes centrales, reportando un NDVI promedio de 0.21 con tendencia decreciente atribuida al crecimiento poblacional. Cano et al. [11] analizaron la degradación de ecosistemas en la meseta del Bombón (Junín) mediante ARVI con series temporales Landsat (1985–2022), encontrando que el 13.4 % de la cobertura vegetal está degradada, con bofedales y pastos altos como las más afectadas. Tatsumi et al. [30] aplicaron clasificación Random Forest sobre Landsat 7 ETM+ para discriminación de cultivos en Perú. Marin et al. [13] estudiaron la dinámica de pastizales en Amazonas utilizando NDVI, EVI y SAVI en GEE. Barboza et al. [24] mapearon áreas quemadas (1986–2023) en Amazonas mediante computación en la nube. En el sur del Perú, Quille-Mamani et al. [12] emplearon índices Landsat y temperatura superficial para monitorear estrés hídrico en olivares, mientras que Montoya-Jara et al. [29] y Durán-Alarcón et al. [26] utilizaron series Landsat para estimar cambios en glaciares de Vilcanota y Cordillera Blanca.

En el departamento de Puno —extremo altitudinal de 220 a 5 589 msnm que transita del altiplano semiárido a la ceja de selva— Canaza et al. [10] investigaron la distribución de carbono orgánico del suelo en el ecosistema altoandino utilizando Kriging Ordinario, revelando que altitud y variables climáticas determinan la acumulación de carbono. Puno concentra además una proporción significativa de los bofedales del altiplano peruano, ecosistemas frágiles que proveen forraje para camélidos y regulan el ciclo hídrico regional. A pesar de estos antecedentes, persiste una brecha: ningún estudio ha integrado autocorrelación espacial (Moran Global y LISA) con modelado geoestadístico (Kriging Ordinario) y estratificación provincial para caracterizar simultáneamente múltiples índices de vegetación en un departamento andino completo. Anselin [1] propuso los LISA como herramienta para descomponer la autocorrelación global en contribuciones locales. Kowe et al. [2] y Moura y Fonseca [3] aplicaron estos métodos al análisis de cobertura vegetal, mientras que Cressie [17] y Goovaerts [18] establecieron las bases de la geoestadística para interpolación de variables biofísicas. Sin embargo, la aplicación conjunta de estos métodos con índices Landsat 8 en territorios andinos de gradiente altitudinal extremo no ha sido documentada.

El presente trabajo aborda esta brecha mediante un pipeline analítico que: (a) cuantifica la autocorrelación espacial de cuatro índices de vegetación en una grilla de 5 km sobre las 13 provincias de Puno, (b) identifica clusters significativos mediante LISA, (c) evalúa la capacidad del Kriging Ordinario para interpolar NDVI y NDMI en una grilla de 2 km con validación cruzada, y (d) estratifica los resultados por provincia para identificar regímenes ecológicos diferenciados con implicancias para la gestión territorial.

2. Método

2.1. Datos

El dataset consta de 3 019 puntos distribuidos en una grilla regular de 5 km sobre el departamento de Puno. Las variables se describen en la Tabla 1.

Cuadro 1: Diccionario de variables

Variable	Descripción	Unidad	Fuente
NDVI	Índice de Vegetación de Dif. Normalizada	Adim. (−1 a 1)	Landsat 8 (NIR, RED)
SAVI	Índice de Vegetación Ajustado al Suelo ($L = 0,5$)	Adim. (−1 a 1)	Landsat 8
EVI	Índice de Vegetación Mejorado	Adim. (−1 a 1)	Landsat 8 (NIR, RED, BLUE)
NDMI	Índice de Humedad de Dif. Normalizada	Adim. (−1 a 1)	Landsat 8 (NIR, SWIR1)
Precip	Precipitación total anual (Bio12)	mm/año	WorldClim v2.1
Temp	Temperatura media anual (Bio01)	°C	WorldClim v2.1
Elevación	Altitud topográfica	msnm	NASA SRTM 30m

Los índices espectrales corresponden a la mediana anual de reflectancia en superficie (TOA) del año 2023, procesada en Google Earth Engine [19] a 30 m de resolución y agregada a la grilla de 5 km. Los datos climáticos provienen de WorldClim v2.1 [20] y los topográficos de la misión SRTM [21]. La consistencia espectral entre sensores Landsat ha sido ampliamente documentada [23], lo que respalda la comparabilidad de los índices calculados sobre productos OLI.

2.2. Preprocesamiento

Las coordenadas geográficas (WGS84, EPSG:4326) se proyectaron a UTM Zona 19S (EPSG:32719) para trabajar con distancias euclidianas en metros. No se detectaron valores nulos ni infinitos en ninguna variable (0 NAs en 3 019 registros).

2.3. Análisis de Correlación

Se calcularon las matrices de correlación de Pearson y Spearman entre los 4 índices espectrales y las 3 variables ambientales.

2.4. Autocorrelación Espacial

La matriz de pesos espaciales se construyó mediante el criterio de k -vecinos más cercanos (k -NN) con $k = 8$, estandarizada por filas (style = “W”). Este criterio garantiza conectividad completa sin islas.

Moran Global: Se calculó el I de Moran univariante para cada índice con 999 permutaciones Monte Carlo ($\alpha = 0,05$, prueba bilateral). Se reportan el estadístico I , el valor esperado $E[I]$, el Z -valor y el p -valor empírico.

Moran Local (LISA): Se aplicó el indicador local de asociación espacial propuesto por Anselin (1995) para NDVI y NDMI. Cada punto se clasificó en uno de cuatro cuadrantes —Alto-Alto (AA), Bajo-Bajo (BB), Alto-Bajo (AB), Bajo-Alto (BA)— cuando el p -valor local fue $< 0,05$.

2.5. Geoestadística: Kriging Ordinario

Semivariograma experimental: Se calculó con el estimador clásico de Matheron (cutoff = 150 km, ancho de lag = 10 km). Se probaron tres modelos —Esférico, Exponencial y Gaussiano— seleccionando el de menor SSErr.

Kriging Ordinario: Grilla regular de 2 km ($121 \times 236 = 28\,556$ celdas), con $n_{\text{máx}} = 50$ vecinos.

Validación Cruzada: 10-fold CV con métricas RMSE, MAE, R^2 y r de Pearson.

2.6. Análisis Provincial

Los 3 019 puntos se asignaron a las 13 provincias de Puno mediante *spatial join* con el shapefile distrital del INEI (2023). Se utilizó `st_intersects` como criterio principal y `st_nearest_feature` para recuperar 69 puntos ubicados a < 1 km del borde provincial. Se excluyeron los 174 puntos restantes, que corresponden al Lago Titicaca ($\text{NDVI} = -0,236$). Muestra provincial efectiva: $n = 2\,845$.

2.7. Software y Disponibilidad de Código

Todos los análisis se realizaron en R 4.4.1 con los paquetes `sf`, `spdep`, `gstat`, `ggplot2`, `corrplot` y `dplyr`. El código fuente completo, los scripts de Google Earth Engine y los datos procesados están disponibles públicamente en GitHub: <https://github.com/valec3/spatial-NDVI>. Los resultados de este pipeline analítico se presentan a continuación, organizados en cinco secciones: descriptivos, correlaciones, autocorrelación espacial, geoestadística y análisis provincial.

3. Resultados

A continuación se presenta el análisis de los 3 019 puntos de la grilla departamental. La exposición sigue el orden del pipeline metodológico: desde la caracterización descriptiva hasta la estratificación provincial, pasando por el modelado de la dependencia espacial.

3.1. Estadísticos Descriptivos

Cuadro 2: Estadísticos descriptivos ($n = 3\,019$)

Variable	Media	SD	Mín	Máx	Asimetría
NDVI	0.305	0.239	-0,576	0.825	-0,019
SAVI	0.195	0.129	-0,166	0.563	0.823
EVI	0.262	0.213	-0,334	0.871	1.158
NDMI	0.026	0.220	-0,324	0.882	0.918
Precip_Anual	1202.1	1023.9	380.0	5999.0	2.144
Temp_Media	8.92	6.80	-1,8	25.4	1.161
Elevacion	3606.7	1324.1	220.0	5589.0	-1,418

El NDVI promedio es 0.305, con un rango que abarca desde valores negativos ($-0,576$, cuerpos de agua y superficies no vegetadas del altiplano) hasta 0.825 (vegetación densa en la ceja de selva). La precipitación presenta una asimetría positiva extrema (2.14, $\text{CV} = 85\%$), reflejando la transición desde el altiplano semiárido hasta la vertiente amazónica hiper-húmeda. La elevación muestra asimetría negativa ($-1,42$): la mayoría de los puntos se concentran sobre 3 000 msnm.

3.2. Matriz de Correlación

Cuadro 3: Matriz de correlación: Pearson (triángulo inferior) y Spearman (triángulo superior)

	NDVI	SAVI	EVI	NDMI	Elevación	Precip	Temp
NDVI	—	0.96	0.95	0.37	−0,51	0.50	0.53
SAVI	0.96	—	0.99	0.44	−0,58	0.48	0.60
EVI	0.92	0.98	—	0.44	−0,59	0.50	0.61
NDMI	0.38	0.55	0.63	—	−0,68	0.58	0.65
Elevación	−0,70	−0,82	−0,90	−0,79	—	−0,59	−0,99
Precip	0.65	0.74	0,83	0.73	−0,90	—	0.58
Temp	0.69	0.81	0,88	0.80	−0,99	0.88	—

Tres hallazgos principales: (1) **alta colinealidad** entre NDVI, SAVI y EVI (Pearson $> 0,92$), mientras NDMI es más independiente ($r = 0,38$ – $0,63$); (2) **dominancia del gradiente altitudinal**: EVI es el índice que mejor se correlaciona con variables ambientales (elevación $r = -0,90$, temperatura $r = 0,88$); (3) **relaciones predominantemente lineales**: Pearson es sistemáticamente mayor que Spearman (ej. EVI-Elevación: $-0,90$ vs. $-0,59$). Esta fuerte intercorrelación entre índices es consistente con lo reportado en otras comparaciones multi-índice [27].

Matriz de Correlacion (Pearson) — Indices de Vegetacion vs Variables Ambientales
Puno, Peru




Figura 1: Matriz de correlación de Pearson entre índices espectrales y variables ambientales.

3.3. Autocorrelación Espacial Global

Cuadro 4: Índice I de Moran Global (k -NN, $k = 8$, 999 permutaciones MC, $\alpha = 0,05$)

Variable	I de Moran	$E[I]$	Z -Valor	p (MC)
EVI	0,9162	−0,0003	101.60	0.000
NDMI	0.8615	−0,0003	95.53	0.000
SAVI	0.8613	−0,0003	95.51	0.000
NDVI	0.8586	−0,0003	95.23	0.000

Los cuatro índices presentan autocorrelación espacial positiva excepcionalmente alta ($p < 0,001$). EVI presenta el I más alto (0.916), consistente con su corrección atmosférica que produce una superficie más suave.

3.4. Análisis LISA: Clusters Locales

Cuadro 5: Distribución de clusters LISA para NDVI y NDMI ($\alpha = 0,05$)

Cluster	NDVI (n)	NDVI (%)	NDMI (n)	NDMI (%)
Alto-Alto (AA)	636	21.1 %	773	25.6 %
Bajo-Bajo (BB)	259	8.6 %	578	19.1 %
Alto-Bajo (AB)	14	0.5 %	1	0.0 %
Bajo-Alto (BA)	28	0.9 %	11	0.4 %
No significativo	2082	69.0 %	1656	54.9 %
Total sig.	937	31.0 %	1363	45.1 %

NDMI detecta sustancialmente más estructura espacial que NDVI (45.1 % vs. 31.0 %). Los clusters AA se concentran en la vertiente oriental (Sandia, Carabaya), mientras los BB en el altiplano sur-occidental (El Collao, Chucuito). Los clusters AB/BA son prácticamente inexistentes (< 1 %), consistente con un gradiente espacial suave y continuo. Este patrón —alta autocorrelación positiva con escasos outliers— coincide con lo documentado por Kowe et al. (2020) en paisajes con baja fragmentación, y refuerza la utilidad del análisis LISA para caracterizar la estructura espacial de la vegetación [3].




Figura 2: Mapas de clusters LISA para NDVI (izquierda) y NDMI (derecha) en el departamento de Puno (k -NN, $k = 8$, 999 permutaciones MC, $\alpha = 0,05$).

3.5. Geoestadística: Semivariograma y Kriging

3.5.1. Parámetros del Semivariograma

Cuadro 6: Parámetros de los semivariogramas ajustados

Parámetro	NDVI	NDMI
Modelo seleccionado	Exponencial	Esférico
Nugget (C_0)	0.005715	0.003565
Sill parcial (C_1)	0.081315	0.051979
Sill total ($C_0 + C_1$)	0.087030	0.055544
Alcance (range)	189.3 km	168.6 km
Nugget/Sill (%)	6.6 %	6.4 %

El nugget es solo 6–7 % del sill, indicando que la señal espacial estructurada explica $> 93\%$ de la varianza. El alcance de ~ 170 – 190 km es consistente con la escala de sistemas montañosos del departamento.




Figura 3: Semivariogramas experimentales y modelos ajustados para NDVI (Exponencial, izquierda) y NDMI (Esférico, derecha).

3.5.2. Superficies Interpoladas



Figura 4: Superficies interpoladas por Kriging Ordinario (grilla 2 km): NDVI (izquierda) y NDMI (derecha).

3.5.3. Validación Cruzada

Cuadro 7: Métricas de validación cruzada (10-fold CV)

Variable	RMSE	MAE	R^2	r Pearson
NDVI	0.0899	0.0567	0.8588	0.9267
NDMI	0.0805	0.0500	0.8663	0.9307

Ambos modelos muestran capacidad predictiva excelente ($R^2 > 0,85$). NDMI presenta rendimiento ligeramente superior, consistente con su mayor estructura espacial en LISA. El RMSE de 0.090 en escala NDVI (-1 a 1) implica un error típico de $\sim 9\%$ del rango total.

3.6. Análisis Provincial

3.6.1. EVI y NDMI por Provincia

Cuadro 8: Estadísticos de EVI, NDVI y NDMI por provincia ($n = 2845$)

Provincia	n	EVI	NDVI	NDMI	Elev (m)	Temp ($^{\circ}\text{C}$)
SANDIA ▲	501	0.581	0.644	0.296	1 727	16.7
CARABAYA ▲	497	0.373	0.416	0.085	2 997	12.5
SAN ANTONIO DE PUTINA	133	0.204	0.300	-0,082	4 432	5.5
HUANCANÉ	126	0.203	0.272	-0,103	4 135	6.9
MELGAR	278	0.184	0.259	-0,111	4 349	5.6
AZÁNGARO	215	0.183	0.255	-0,133	4 140	6.3
YUNGUYO [†]	14	0.178	0.215	0.009	3 955	8.0
SAN ROMÁN	95	0.171	0.226	-0,077	4 125	7.2
MOHO	41	0.168	0.231	-0,118	4 108	8.7
CHUCUITO	172	0.166	0.223	-0,087	4 109	7.0
LAMPA	240	0.163	0.220	-0,076	4 428	5.5
PUNO	289	0.163	0.212	-0,076	4 208	6.6
EL COLLAO ▼	244	0.143	0.189	-0,079	4 351	5.9

[†] Yunguyo ($n = 14$): estimaciones no confiables. No se recomienda su inclusión en inferencias provinciales.

Sandia presenta un EVI promedio de 0.581 —aproximadamente el triple del promedio departamental— mientras El Collao registra el más bajo (0.143). Diez de las trece provincias tienen NDMI negativo, reflejando estrés hídrico generalizado.




Figura 5: Mapa coroplético de EVI promedio por provincia, Puno.




Figura 6: NDVI y NDMI promedio por provincia, ordenados por NDVI descendente.

3.6.2. Gradiente Altitudinal Intra-Provincial

Cuadro 9: Correlación EVI-Elevación por provincia con test de significancia

Provincia	<i>n</i>	<i>r</i> (EVI-Elev)	<i>p</i>	Sig.
CARABAYA	497	−0,944	< 0,001	***
SANDIA	501	−0,916	< 0,001	***
SAN ANTONIO DE PUTINA	133	−0,735	< 0,001	***
EL COLLAO	244	−0,626	< 0,001	***
SAN ROMÁN	95	−0,576	< 0,001	***
CHUCUITO	172	−0,492	< 0,001	***
LAMPA	240	−0,448	< 0,001	***
PUNO	289	−0,432	< 0,001	***
MELGAR	278	−0,260	< 0,001	***
HUANCANÉ	126	+0,222	0.013	*
AZÁNGARO	215	+0,013	0.850	ns
MOHO	41	+0,052	0.747	ns
YUNGUYO†	14	−0,036	0.902	ns

El análisis revela cuatro regímenes: (1) **gradiente fuerte** en Sandia, Carabaya y Putina ($r < -0,73$, $R^2 > 0,54$); (2) **gradiente moderado** en El Collao, San Román, Chucuito, Lampa y Puno ($-0,63 < r < -0,43$); (3) **altiplano homogéneo** en Melgar ($r = -0,26$); y (4) **gradiente positivo significativo** en Huancané ($r = +0,222$, $p = 0,013$). Este patrón es consistente con la presencia de bofedales altoandinos —humedales con vegetación densa— en las zonas más elevadas de Huancané. En contraste, las áreas bajas cercanas al lago presentan suelos salinos con vegetación rala. Estudios sobre la distribución espacial del carbono orgánico en suelos altoandinos de Puno [10] también revelan una heterogeneidad espacial que responde a factores topográficos y de uso de suelo, lo cual es congruente con los regímenes diferenciados que aquí se identifican. Sin embargo, la interpretación del gradiente positivo en Huancané requiere validación con datos de campo sobre la distribución espacial de bofedales en la provincia.




Figura 7: EVI vs. Elevación por provincia con rectas de regresión lineal.

3.6.3. Multicolinealidad entre Índices

Cuadro 10: Diagnóstico de multicolinealidad (VIF)

Índice	R^2 contra otros	VIF	Diagnóstico
SAVI	0.985	68.6	Altamente redundante
EVI	0.975	39.7	Altamente redundante
NDVI	0.952	20.8	Redundante
NDMI	0.762	4.2	Independiente

NDVI, SAVI y EVI miden esencialmente la misma dimensión biofísica. NDMI es el único índice independiente. En este estudio, el par EVI + NDMI capturó adecuadamente tanto la biomasa fotosintética como el contenido de agua. Ambos índices pueden ser suficientes para caracterizar la vegetación en territorios con gradientes altitudinales marcados como el de Puno. Esta redundancia entre índices de biomasa ha sido documentada también en pastizales semiáridos [16] y en zonas de montaña de Asia Central [7].

4. Discusión

4.1. El gradiente altitudinal como estructurador del paisaje vegetal

Un hallazgo es contundente: la dominancia del gradiente altitudinal sobre la vegetación en Puno. La correlación EVI-Elevación ($r = -0,90$) y la relación Elevación-Temperatura ($r = -0,99$) indican que el control topográfico opera a través del gradiente adiabático. Carbajal-Morán et al. (2023) y Cano et al. (2023) documentaron que los pisos ecológicos andinos son fundamentalmente pisos térmicos, un resultado que nuestros datos confirman con notable precisión. Y esa precisión es la que abre la puerta a aplicaciones prácticas.

¿Qué implicancias tiene este hallazgo para la planificación territorial? En nuestra opinión, si la altitud organiza la vegetación de manera tan predecible, las políticas de conservación y uso del suelo podrían diseñarse en función de pisos ecológicos bien definidos, en lugar de fronteras administrativas. Trabajos recientes en cordilleras peruanas, como el monitoreo de glaciares en la Cordillera Vilcanota [29] y el análisis de retroceso glaciar en la Cordillera Blanca [26], ambos con imágenes Landsat, refuerzan la viabilidad de este enfoque satelital para múltiples aplicaciones en los Andes.

4.2. Superioridad de EVI en zonas de montaña

EVI presentó el mejor desempeño en todas las métricas. ¿Por qué? Tres factores, específicos de las condiciones de Puno, confluyen aquí. Primero, la atmósfera delgada a $> 3\,500$ m magnifica los errores que EVI corrige con la banda azul. Segundo, los suelos desnudos del altiplano afectan menos a SAVI y EVI que a NDVI. Y tercero, NDVI tiende a saturarse en las zonas de vegetación densa ($> 0,7$), aplanando la relación con la altitud en la ceja de selva. Este último punto es bien conocido: el NDVI convencional pierde sensibilidad en coberturas altas, y por ello se han propuesto generalizaciones no lineales que mejoran su desempeño [25]. Ma et al. (2024) y Li et al. (2025) reportan ventajas comparables de EVI en terrenos montañosos, y nuestros resultados extienden esa evidencia al altiplano peruano. La generalización de estos hallazgos a otras regiones andinas requeriría, sin embargo, estudios con condiciones atmosféricas y de cobertura vegetal diferentes. La comparación de múltiples índices espectrales en aplicaciones de downscaling espacial [22] sugiere que la elección del índice óptimo depende fuertemente del contexto geográfico.

4.3. NDMI: la dimensión oculta de la humedad

NDMI revela el doble de estructura espacial que NDVI (45.1 % vs. 31.0 %) y es el único índice independiente ($VIF = 4.2$). Esa diferencia importa. Sus clusters Bajo-Bajo (19.1 %) identifican zonas con estrés hídrico que los índices de biomasa no capturan. En concreto, el 67.7 % de los puntos muestreados en Puno presenta NDMI negativo, siendo las provincias de Azángaro ($-0,133$) y Moho ($-0,118$) las que registran los valores más bajos. Este hallazgo es preocupante: dos tercios del departamento bajo condiciones de déficit hídrico. Quille-Mamani et al. (2024) documentaron la utilidad de índices derivados de Landsat para monitorear estrés hídrico en cultivos del sur del Perú, en línea con estos resultados. Pero la señal de NDMI va más allá de los cultivos: refleja un patrón departamental de sequedad que afecta tanto a zonas agrícolas como a ecosistemas naturales. El monitoreo de la respuesta de la vegetación a la sequía mediante NDVI de Landsat 8 ha mostrado patrones comparables en otras regiones [28].

4.4. Implicancias del Kriging para el monitoreo ambiental

La capacidad predictiva ($R^2 > 0,85$) con solo 3019 puntos de muestreo es notable. Implica que con una inversión modesta se puede generar información de alta resolución para todo el departamento. Cressie (1993) y Goovaerts (1997) ya demostraron la potencia del Kriging en variables biofísicas; lo que aquí se aporta es su aplicación conjunta con índices Landsat 8 en un territorio andino con gradientes extremos. Las superficies de 2023 proveen una línea base para detectar cambios futuros en cobertura vegetal, en línea con el monitoreo de tierras altas peruanas realizado por Cano et al. (2023). La reconstrucción de series temporales de índices de vegetación mediante métodos geoestadísticos y de aprendizaje automático [31] ofrece una vía prometedora para extender este análisis a múltiples años. We argue that este enfoque híbrido — estadística espacial más geoestadística — es particularmente útil en regiones montañosas donde la topografía impone una fuerte estructura a los datos.

Queda por responder si este enfoque puede replicarse en otros departamentos andinos con condiciones geomorfológicas distintas. La combinación de extensión areal, gradiente altitudinal y baja cobertura nubosa hace de Puno un caso particularmente favorable para el monitoreo satelital. Evaluar la transferibilidad del método a regiones con mayor nubosidad —como la ceja de selva en Cusco o Madre de Dios— constituye una línea de investigación futura. This raises a deeper question: ¿podría la integración de datos Sentinel-2 y Landsat 8, con sus frecuencias de revisita complementarias, mitigar parcialmente las limitaciones de nubosidad en esas zonas?

4.5. Limitaciones

El estudio presenta seis limitaciones principales. (1) **Temporalidad**: corte transversal de 2023, sin capacidad de inferir tendencias. Series temporales con múltiples años, como las empleadas por Liu et al. (2023) para NDVI en la plataforma GEE, permitirían detectar cambios en la vegetación a largo plazo. (2) **Resolución de grilla**: 5 km puede no capturar micro-variabilidad en zonas de transición abrupta. (3) **Validación**: solo validación cruzada interna, sin mediciones de campo independientes. (4) **Multicolinealidad**: NDVI, SAVI y EVI son redundantes ($VIF > 20$). La comparación sistemática de índices en zonas semiáridas [16] sugiere que futuros estudios podrían limitarse a EVI y NDMI. (5) **Cobertura provincial**: Yunguyo ($n = 14$) no permite inferencias confiables. (6) **Efecto de borde**: el shapefile INEI tiene un offset de ~ 500 m que afectó al 2.3 % de los puntos, recuperados mediante asignación por vecino más cercano.

5. Conclusiones

1. Los índices de vegetación espectral en Puno presentan una **autocorrelación espacial positiva extremadamente alta** (I de Moran 0,859–0,916, $p < 0,001$), estructurada por el gradiente altitudinal andino. EVI captura este gradiente mejor que NDVI y SAVI (EVI-Elevación $r = -0,898$).
2. **NDVI, SAVI y EVI son altamente redundantes** ($VIF > 20$) en este estudio. NDMI es el único índice independiente ($VIF = 4,2$). El par EVI + NDMI capturó tanto la biomasa fotosintética como la humedad de la vegetación sin redundancia. Ambos índices pueden ser suficientes para caracterizar la vegetación en territorios con gradientes altitudinales como el de Puno.
3. **NDMI revela el doble de estructura espacial** que NDVI en LISA (45.1 % vs. 31.0 %), identificando zonas de estrés hídrico invisibles para índices de biomasa. El 67.7 % de Puno presenta NDMI negativo.
4. El **Kriging Ordinario alcanza** $R^2 > 0,85$ en validación cruzada, con alcances de 170–190 km y nuggets de solo 6–7 % del sill.
5. **El análisis provincial revela cuatro regímenes** EVI-altitud, incluyendo un gradiente positivo significativo en Huancané ($r = +0,222$, $p = 0,013$). Este patrón es consistente con la presencia de bofedales altoandinos en zonas elevadas, aunque esta interpretación requiere validación independiente con datos de campo.
6. La integración de índices espectrales, variables ambientales, geoestadística y estratificación provincial constituye una **herramienta viable para el monitoreo ambiental** en territorios de alta montaña, proveyendo una línea base para políticas territoriales diferenciadas.

Referencias

- [1] Anselin, L. (1995). Local Indicators of Spatial Association—LISA. *Geographical Analysis*, 27(2), 93–115.
- [2] Kowe, P., Mutanga, O., Odindi, J. & Dube, T. (2020). A quantitative framework for analysing long term spatial clustering and vegetation fragmentation in an urban landscape using multi-temporal Landsat data. *Int. J. Applied Earth Observation and Geoinformation*, 88, 102057.
- [3] Moura, A.C. & Fonseca, B. (2020). ESDA of Vegetation Cover in Urban Areas—Recognition of Vulnerabilities for the Management of Resources in Urban Green Infrastructure. *Sustainability*, 12(5), 1933.
- [4] Xue, J. & Su, B. (2017). Significant Remote Sensing Vegetation Indices: A Review of Developments and Applications. *Journal of Sensors*, 2017, 1353691.
- [5] Ma, Y., He, T., McVicar, T.R., Liang, S., Liu, T., Peng, W., Song, D.-X. & Tian, F. (2024). Quantifying how topography impacts vegetation indices at various spatial and temporal scales. *Remote Sensing of Environment*, 312, 114311.
- [6] Yan, K., Gao, S., Yan, G., Ma, X., Chen, X., Zhu, P., Li, J., Gastellu-Etchegorry, J., Myneni, R. & Wang, Q. (2025). A global systematic review of the remote sensing vegetation indices. *Int. J. Applied Earth Observation and Geoinformation*.
- [7] Li, Q., Cheng, J., Yan, J., Zhang, G. & Ling, H. (2025). Comparison of Satellite-Derived Vegetation Indices for Assessing Vegetation Dynamics in Central Asia. *Water*, 17(5).
- [8] Vidican, R., Malinas, A., Ranta, O., Moldovan, C., Marian, O., Ghețe, A., Ghișe, C.R., Popovici, F. & Cătunescu, G.M. (2023). Using Remote Sensing Vegetation Indices for the Discrimination and Monitoring of Agricultural Crops: A Critical Review. *Agronomy*, 13(12).
- [9] Carbajal-Morán, H., Márquez-Camarena, J.F., Galván-Maldonado, C.A., Zárate-Quñones, R.H., Galván-Maldonado, A.C. & Muñoz-De la Torre, R.J. (2023). Evaluation of Normalized Difference Vegetation Index by Remote Sensing with Landsat Satellites in the Tayacaja Valley in the Central Andes of Peru. *Ecological Engineering & Environmental Technology*, 24(7), 208–215.
- [10] Canaza, D., Calizaya, E., Chambi, W., Calizaya, F., Mindani, C., Cuentas, O., Caira, C. & Huacani, W. (2023). Spatial Distribution of Soil Organic Carbon in Relation to Land Use, Based on the Weighted Overlay Technique in the High Andean Ecosystem of Puno—Peru. *Sustainability*, 15(13), 10316.
- [11] Cano, D., Pizarro, S., Cacciuttolo, C., Peñaloza, R., Yaranga, R. & Gandini, M. (2023). Study of Ecosystem Degradation Dynamics in the Peruvian Highlands: Landsat Time-Series Trend Analysis (1985–2022) with ARVI for Different Vegetation Cover Types. *Sustainability*, 15(21), 15472.
- [12] Quille-Mamani, J.A., Huayna, G., Pino-Vargas, E., Chucuya-Mamani, S., Vera-Barrios, B., Ramos-Fernández, L., Espinoza-Molina, J. & Cabrera-Olivera, F. (2024). Spatio-Temporal Evolution of Olive Tree Water Status Using Land Surface Temperature and Vegetation Indices Derived from Landsat 5 and 8 Satellite Imagery in Southern Peru. *Agriculture*, 14(5), 662.

- [13] Marin, N.A., Barboza, E., López, R., Vásquez, H., Gómez Fernández, D., Terrones Murga, R.E., Rojas Briceño, N.B., Oliva-Cruz, M., Gamarra Torres, O.G., Silva López, J.O. & Cayo, E.T. (2022). Spatiotemporal Dynamics of Grasslands Using Landsat Data in Livestock Micro-Watersheds in Amazonas (NW Peru). *Land*, 11(5), 674.
- [14] Fayeche, D. & Tarhouni, J. (2020). Climate Variability and Its Effect on Normalized Difference Vegetation Index (NDVI) Using Remote Sensing in Semi-Arid Area. *Modeling Earth Systems and Environment*, 7, 1667–1682.
- [15] Liu, Z., Chen, Y. & Chen, C. (2023). Analysis of the Spatiotemporal Characteristics and Influencing Factors of the NDVI Based on the GEE Cloud Platform and Landsat Images. *Remote Sensing*, 15(20), 4980.
- [16] Rajabov, T., Ramsey, R.D., Mardonov, B., Nasirov, M.G., Rakhimova, T. & Valiev, S.A. (2020). Sensitivity of Landsat 7 & 8-derived vegetation indices on semi-arid rangelands of southwestern Uzbekistan. *Geocarto International*, 37(2), 510–525.
- [17] Cressie, N. (1993). *Statistics for Spatial Data* (Revised ed.). Wiley.
- [18] Goovaerts, P. (1997). *Geostatistics for Natural Resources Evaluation*. Oxford University Press.
- [19] Gorelick, N., Hancher, M., Dixon, M., Ilyushchenko, S., Thau, D. & Moore, R. (2017). Google Earth Engine: Planetary-scale geospatial analysis for everyone. *Remote Sensing of Environment*, 202, 18–27.
- [20] Fick, S.E. & Hijmans, R.J. (2017). WorldClim 2: new 1-km spatial resolution climate surfaces for global land areas. *International Journal of Climatology*, 37(12), 4302–4315.
- [21] Farr, T.G., Rosen, P.A., Caro, E., Crippen, R., Duren, R., Hensley, S., Kobrick, M., Paller, M., Rodriguez, E., Roth, L., Seal, D., Shaffer, S., Shimada, J., Umland, J., Werner, M., Oskin, M., Burbank, D. & Alsdorf, D. (2007). The Shuttle Radar Topography Mission. *Reviews of Geophysics*, 45, RG2004.
- [22] Alexander, T.H., Luan, H., Jin, H. & Duan, Z. (2025). Spatial Downscaling of Gridded Soil Moisture Products Using Optical and Thermal Satellite Data: Effect of Using Different Vegetation Indices. *IEEE J. Selected Topics in Applied Earth Observations and Remote Sensing*, 18, 7728–7745.
- [23] Arekhi, M., Goksel, C., Sanli, F.B. & Senel, G. (2019). Comparative Evaluation of the Spectral and Spatial Consistency of Sentinel-2 and Landsat-8 OLI Data for Igneada Longos Forest. *ISPRS Int. J. Geo-Information*, 8(2), 56.
- [24] Barboza, E., Turpo, E.Y., Tariq, A., Salas López, R., Pizarro, S., Zabaleta-Santisteban, J.A., Medina-Medina, A.J., Tuesta-Trauco, K.M., Oliva-Cruz, M. & Vásquez, H.V. (2024). Spatial Distribution of Burned Areas from 1986 to 2023 Using Cloud Computing: A Case Study in Amazonas (Peru). *Fire*, 7(11), 413.
- [25] Camps-Valls, G., Campos-Taberner, M., Moreno-Martínez, Á., Walther, S., Duveiller, G., Cescatti, A., Mahecha, M.D., Muñoz-Marí, J., García-Haro, F.J., Guanter, L., Jung, M., Gamon, J.A., Reichstein, M. & Running, S.W. (2021). A unified vegetation index for quantifying the terrestrial biosphere. *Science Advances*, 7(9), eabc7447.
- [26] Durán-Alarcón, C., Gevaert, C.M., Mattar, C., Jiménez-Muñoz, J.C., Pasapera-Gonzales, J.J., Sobrino, J.A., Silvia-Vidal, Y., Fashé-Raymundo, O., Chavez-Espiritu, T.W. & Santillan-Portilla, N. (2015). Recent trends on glacier area retreat over the group of Ne-

- vados Caullaraju-Pastoruri (Cordillera Blanca, Peru) using Landsat imagery. *Journal of South American Earth Sciences*, 59, 19–26.
- [27] Madonsela, S., Cho, M.A., Ramoelo, A. & Mutanga, O. (2017). Remote sensing of species diversity using Landsat 8 spectral variables. *ISPRS J. Photogrammetry and Remote Sensing*, 133, 116–127.
 - [28] Mirzaee, S. & Mirzakhani Nafchi, A. (2023). Monitoring Spatiotemporal Vegetation Response to Drought Using Remote Sensing Data. *Sensors*, 23(4), 2134.
 - [29] Montoya-Jara, N., Loayza, H., Gutiérrez-Rosales, R.O., Bueno, M. & Quiroz, R. (2024). Estimation of Glacier Outline and Volume Changes in the Vilcanota Range Snow-Capped Mountains, Peru, Using Temporal Series of Landsat and a Combination of Satellite Radar and Aerial LIDAR Images. *Remote Sensing*, 16(20), 3901.
 - [30] Tatsumi, K., Yamashiki, Y., Morales Morante, A.K., Ramos Fernández, L. & Apaclla Nalvarte, R. (2016). Pixel-based crop classification in Peru from Landsat 7 ETM+ images using a Random Forest model. *Journal of Agricultural Meteorology*, 72(1), 1–11.
 - [31] Xiong, C., Ma, H., Liang, S., He, T., Zhang, Y., Zhang, G. & Xu, J. (2023). Improved global 250 m 8-day NDVI and EVI products from 2000–2021 using the LSTM model. *Scientific Data*, 10, 800.